



DataScientest • com

RAPPORT TECHNIQUE D'EVALUATION

PROJET MVPY

Prédiction de l'issue d'un tir en NBA



Promotion : **Data Analyst - Septembre 2021**

Participants : **Julien LICKEL, Benjamin PIEROTTI, Cyrille CLAIRE**

Table des matières

1. Introduction	1
1.1. Présentation du projet et objectifs	1
1.2. Contexte	1
2. Les données	2
2.1. Analyse exploratoire	2
2.2. Description et compréhension des variables.....	2
2.3. Nettoyage.....	3
2.4. Création de nouvelles variables	4
3. Comparaison des tirs de 20 des meilleurs joueurs NBA du 21ème siècle	5
3.1. Comparaison des habitudes de tirs des 20 joueurs par poste.....	5
3.1.1. Les pivots	5
3.1.2. Les meneurs	7
3.1.3. Les arrières.....	11
3.1.4. Les ailiers / ailiers forts	13
3.1.5. Synthèse.....	15
4. Prédiction de l'issue d'un tir pour les 10 joueurs en activité	16
4.1. Pourquoi regrouper les joueurs selon leur poste ?	16
4.2. Le choix de la métrique de classification	17
4.3. Répartition des tâches entre les membres du groupe	18
4.4. La procédure d'évaluation des modèles	18
4.5. Démarche de travail.....	19
4.5.1. Test d'un premier modèle	19
4.5.2. Réglage du jeu de données	19
4.5.3. Recherche des types de modèles prometteurs.....	20
4.5.4. Optimisation d'hyper paramètres par GridSearch	20
4.5.5. Comparaison des types de modèles optimisés	20
4.5.6. Evaluation finale	20
5. Modélisation	21
5.1.1. Les groupes de joueurs	21
5.1.2. Analyses	22
5.1.3. Résultats finaux	27
5.1.4. Courbes ROC	30
6. Conclusion finale	31

1. Introduction

1.1. Présentation du projet et objectifs

Tim Duncan, Kobe Bryant, Allen Iverson, Steve Nash, Ray Allen, Paul Pierce, Pau Gasol, Tony Parker, Manu Ginobili, Dwyane Wade, LeBron James, Chris Paul, Kevin Durant, Russell Westbrook, Stephen Curry, James Harden, Kawhi Leonard, Damian Lillard, Anthony Davis, Giannis Antetokounmpo : la plupart de ces 20 noms ne vous disent peut-être rien, et pourtant... Ce sont 20 des meilleurs joueurs NBA du 21ème siècle, selon le média américain ESPN. Certains d'entre eux (Kobe Bryant, LeBron James) font même partie des débats récurrents visant à déterminer qui est le GOAT (**G**reatest **O**f **A**ll **T**ime) de la NBA.

Mais quelles sont (ou étaient) les habitudes et routines de tir de ces grands noms du basketball, et serions-nous capables de prévoir l'issue de leur tir suivant le contexte de leur prise de tir ?

1.2. Contexte

Téléportons-nous un bref instant aux Etats-Unis, un pays où la NBA et l'analyse de données règnent en maître sur le monde du sport.

Dans ce sport, chaque franchise NBA possède son équipe complète de data analysts et data scientists, dédiée à l'étude des performances des joueurs et équipes adverses de la ligue : admettons que notre groupe projet soit membre de l'équipe d'analystes d'une franchise NBA.

Lorsque surviennent des matchs face à des équipes dans lesquelles jouent des stars mondiales du basketball comme Kevin Durant, LeBron James, James Harden, etc..., redoutables en attaque, mieux vaut avoir une bonne stratégie pour les contenir au maximum et les empêcher de développer leur jeu d'attaque à la perfection sous peine de concéder des dizaines et des dizaines de points juste grâce à ces joueurs.

L'entraîneur nous confie donc une mission : à partir des données de tirs de 10 des meilleurs joueurs actuels récoltées depuis le début de leur carrière, il voudrait que nous concevions un modèle de classification permettant de prédire, selon le contexte, si le joueur va marquer ou rater son tir.

Grâce à ce modèle, l'objectif pour l'entraîneur sera :

- D'identifier d'éventuels contextes dans lesquels le joueur en question excelle au tir, afin d'orienter le choix du défenseur direct à placer sur ce joueur et le traitement défensif à appliquer.
- Au contraire, d'identifier d'éventuels contextes dans lesquels le joueur est en difficulté au tir, afin là aussi d'adapter la défense et éventuellement pousser le joueur à attaquer dans une zone "défavorable", ou sa probabilité de marquer est plus faible.

2. Les données

2.1. Analyse exploratoire

Le Dataset que nous avons étudié comporte des données sur les tirs des joueurs de NBA entre 1997 et 2019. Il possède **4 729 512 lignes**, mais nous avons décidé de porter notre étude uniquement sur 20 joueurs (soit **350 867** lignes conservées).

Ce jeu de données est disponible [au lien suivant](#).

Curieusement, nous ne notons la présence d'aucune donnée manquante ni d'aucun doublon dans ce dataset initialement très propre.

2.2. Description et compréhension des variables

Le jeu de données initial (avant nettoyage), possède **22 variables** que nous décrivons ci-dessous :

VARIABLE	TYPE	DESCRIPTION
Game ID	Catégorielle	ID du match
Game Event ID	Catégorielle	ID de l'événement de jeu (= ID du tir)
Player ID	Catégorielle	ID du joueur qui a tiré
Player Name	Catégorielle	Nom du joueur qui a tiré
Team ID	Catégorielle	ID de l'équipe du joueur qui a tiré
Team Name	Catégorielle	Nom de l'équipe du joueur qui a tiré
Period	Catégorielle	Période (quart-temps) lors duquel est pris le tir
Minutes Remaining	Quantitative	Nombre de minutes restant avant la fin du quart-temps en cours
Seconds Remaining	Quantitative	Nombre de secondes restant avant la fin de la minute de jeu du quart-temps en cours
Action Type	Catégorielle	Contexte du tir, action amenant au tir (course, lâché, valeur)
Shot Type	Quantitative	La valeur du tir pris, en points
Shot Zone Basic	Catégorielle	Zone du terrain dans laquelle se situe le tireur au moment de déclencher son tir (découpage en 7 zones)
Shot Zone Area	Catégorielle	Localisation du tireur par rapport au panier au moment du tir (découpage en 6 zones)
Shot Zone Range	Catégorielle	Distance du joueur avec le panier au moment du déclenchement du tir (catégorisation de "Shot Distance")
Shot Distance	Quantitative	Distance entre le joueur et le panier au moment du tir
X Location	Quantitative	Coordonnée X du tireur au moment de déclencher
Y Location	Quantitative	Coordonnée Y du tireur au moment de déclencher
Shot Made Flag	Catégorielle (binaire)	VARIABLE CIBLE : finalité du tir (marqué ou raté)
Game Date	Date	Date à laquelle a eu lieu le match
Home Team	Catégorielle	Équipe jouant à domicile lors de ce match
Away Team	Catégorielle	Équipe jouant à l'extérieur lors de ce match
Season Type	Catégorielle	Phase de la compétition (saison régulière ou Playoffs)

2.3. Nettoyage

Afin de faciliter leur utilisation, le nettoyage et le filtrage des données sont opérés via des fonctions. Voici ce que nous avons fait :

- Filtrage du Dataset sur les 20 joueurs que nous avons sélectionnés.
- La variable "Team Name" regroupe les noms des équipes depuis 1997 : certaines équipes ayant changé de noms entre 1997 et aujourd'hui, nous avons décidé d'uniformiser l'ensemble en n'utilisant que les noms d'équipes les plus récents. Nous avons effectué la même opération pour les sigles associés aux noms d'équipes (variables "Home Team" et "Away Team").
- Conversion de la variable "Game Date" au format date.
- Regroupement des valeurs de la variable 'Action Type' en **11 catégories au lieu de 70** :
 - o Layup Shot
 - o Dunk Shot
 - o Floating Shot
 - o Fadeaway
 - o Step Back Shot
 - o Hook Shot
 - o Tip Shot
 - o Putback Shot
 - o Pull-up Shot
 - o Alley oop
 - o Jump Shot
- Création d'une variable "Time Remaining" qui permet, à partir des variables "Minutes Remaining" et "Seconds Remaining", d'avoir le temps restant après un tir tenté sous la forme mm:ss.
- Suppression des colonnes "Minutes Remaining", "Seconds Remaining", "Game ID", "Team ID", "Player ID", "Away Team", et "Home Team".
- Mise en minuscules de toutes les modalités de toutes les colonnes, hors colonnes 'Home Team' et 'Away Team'.
- Remplacement des modalités de la variable "shot zone area", pour plus de maniabilité.
- Mise en minuscules de tous les noms de colonnes (exemple : "right side(r)" devient "right side").
- Remplacement des noms d'équipes complets de la colonne "team name" par leur sigle associé.
- Calcul des distances de tirs exactes avec le théorème de Pythagore (grâce aux variables de localisation "x location" et "y location"), et mise à jour de la variable "shot distance".
- Création d'une variable binaire 'home', indiquant 1 si le joueur était à domicile et 0 sinon.
- Création d'une colonne 'adversary' contenant le nom de l'équipe adverse face à laquelle le joueur a pris son tir.
- Création de 4 nouvelles colonnes : "conference", "division", "conference adv" et "division adv".

2.4. Création de nouvelles variables

Comme évoqué ci-dessus, quelques variables non présentes initialement dans le jeu de données ont été créées, soit de toute pièce (“conference”, “conference adv”, “division”, “division adv”) soit à partir de variables déjà existantes (“time remaining”, “home” et “adversary”).

Les 4 premières variables ont été construites avec l’objectif d’obtenir plus d’informations et donc de chercher à obtenir un modèle éventuellement plus performant : afin d’éviter de longs déplacements à travers tous les Etats-Unis, la NBA a décidé de regrouper les **30 équipes** de la ligue en **2 conférences de 15 équipes** (Ouest et Est) et en **6 divisions de 5 équipes** (3 divisions par conférence) suivant la proximité géographique des franchises, avec la règle suivante : lors de la saison régulière, chaque équipe joue **82 matchs** dont **4 matchs** contre chacune des équipes de sa propre division (= 16 matchs au total), **3 ou 4 matchs** contre les 10 autres équipes de sa conférence mais qui ne sont pas de sa division (= 36 matchs au total) et **2 matchs** contre chacune des 15 équipes de la conférence adverse (= 30 matchs au total).



Illustration de la répartition des 30 franchises NBA en 2 conférences et 6 divisions.

Ainsi, le calendrier des matchs de chaque équipe est asymétrique : les équipes n’ont pas toutes un calendrier équivalent, la difficulté du calendrier dépend donc de la qualité de la division et de la conférence dans laquelle se trouve la franchise.

Une équipe peut ainsi se retrouver à jouer davantage une équipe mal placée qu’une équipe bien classée car elle se trouve dans une division moins compétitive.

Les variables “time remaining”, “adversary” et “home” ont quant à elles été construites à partir de variables initialement présentes dans le jeu de données, mais dont l’interprétation et l’usage tel quel aurait été compliqué pour la suite.

3. Comparaison des tirs de 20 des meilleurs joueurs NBA du 21ème siècle


3.1. Comparaison des habitudes de tirs des 20 joueurs par poste

Nous avons ici regroupé les 20 joueurs de la liste selon leur poste : en effet, un pivot et un meneur n'ont pas grand-chose en commun, tant sur le plan physique que sur le plan du style de jeu ou même de l'espace occupé en attaque.

Il serait donc farfelu de comparer les tirs de 2 joueurs jouant sur ces 2 postes, en tout cas en termes de fréquences de tirs.

3.1.1. Les pivots

Comparaison en termes de fréquence de tirs tentés par zone :



- ⇒ Pour les 3 joueurs, les deux zones dans lesquelles le plus grand pourcentage de tirs est tenté sont **la zone restrictive** (orange) avec pour chacun **plus d'un tiers des tirs tentés dans cette zone**, et **la zone mi-distance** (violet) dans laquelle ils tentent chacun entre 29 % et 35 % de leurs tirs : rien de très surprenant à cela, puisque le jeu d'un pivot au basket se situe majoritairement autour du panier, voir même au contact du panier. Leur grande taille et leur physique souvent massif font qu'il est souvent beaucoup plus aisé pour eux de marquer proche du panier.
- ⇒ **La raquette** (vert) est également un des lieux de tir favoris des pivots, ce qui se vérifie avec Tim Duncan et Pau Gasol. Cependant, une différence importante est à noter entre les 3 joueurs sur ce point : bien que Duncan et Gasol tirent presque indifféremment dans la zone restrictive, dans la raquette ou à mi-distance, Anthony Davis tire assez peu dans la raquette par rapport à ces 2 joueurs (presque 9 % du temps en moins).

On remarque d'ailleurs que cet écart en défaveur de Davis dans la raquette est quasiment comblé par l'écart entre les proportions de tirs tentés derrière **l'arc des 3 points** des trois joueurs : alors que Duncan et Gasol n'ont quasiment jamais tiré derrière l'arc de toute leur carrière, ce n'est pas le cas de Davis, qui aime bien sortir en poste et prendre du champ afin de dégainer de loin (7 % du temps), ce qui le rend d'autant plus dangereux en attaque et surtout difficile à défendre.

- ⇒ Enfin, comme on pouvait s'y attendre, quasiment aucun tir n'est tenté dans **les corners** (couloirs le long des touches) par ces 3 joueurs avec moins d'1 % du total des tirs tentés dans cette zone, une zone de tir essentiellement pratiquée par les arrières.

Comparaison en termes de réussite au tir par zone :

- ⇒ **Zone restrictive** (orange) : le plus efficace dans cette zone se nomme **Anthony Davis**, avec **plus de 70 % de réussite**. Cependant, Tim Duncan et Pau Gasol ne sont pas en reste, avec des pourcentages de réussite assez proches.

Il s'agit de la zone du terrain dans laquelle la probabilité de marquer est la plus élevée, car la distance de tir est la plus faible. Les pivots utilisent très souvent le layup, le dunk et le alley oop dans pour tirer depuis cette zone, des tirs généralement simples à marquer, d'autant plus qu'un règle NBA stipule que tout défenseur situé dans la zone restrictive ne se verra jamais attribué de passage en force. Un pivot bien servi dans cette zone a donc de grandes chances de marquer, ce qui explique ces pourcentages de réussite très élevés pour les 3 joueurs.

Notons cependant que Davis ayant commencé sa carrière NBA en 2013, il a joué beaucoup moins de matchs que ses 2 compères dans sa carrière, ce qui se vérifie avec le nombre de tirs tentés dans cette zone (plus du double de tirs tentés pour Duncan et Gasol) : on peut donc se demander si avec le temps, Davis parviendra à garder une telle efficacité au tir dans la zone restrictive...

- ⇒ **Raquette** (vert) : Là encore, **Anthony Davis** domine le classement, mais les taux de réussite des 3 joueurs sont extrêmement proches.

Notons, pour chacun d'eux, la grande différence entre le taux de réussite dans la raquette et celui dans la zone restrictive !

Une des explications réside dans la pression défensive exercée, beaucoup plus forte dans la raquette que dans la zone restrictive (comme mentionné ci-dessus avec la règle du passage en force).

Mais il y a également le paramètre "distance" à prendre en compte, car la raquette est plutôt large (4,8 m de largeur pour 5,5 m de hauteur) et la distance panier-tireur est plus importante ici que dans la zone restrictive.

- ⇒ **Mi-distance** (violet) : cette fois-ci, le plus performant se nomme **Pau Gasol**, l'espagnol dominant de peu Duncan et Davis sur ce spot de tir.

Le tir à mi-distance est l'un des tirs dont la probabilité de rentrer est la plus faible avec les tirs à 3 points : en effet, le tireur n'est ni proche ni très loin du panier et l'angle de tir peut varier de 0° à 180°. Pour rentrer, un tir pris dans cette zone requiert donc un très bon touché de balle ainsi qu'un bon dosage et à ce jeu-là, Gasol est le meilleur.

Notons que les taux de réussite dans cette zone sont quasiment équivalents à ceux de la raquette pour les 3 joueurs, ce qui est assez remarquable !

- ⇒ **Arc des 3 points** (marron) : Une nouvelle fois, **Pau Gasol** est le plus précis des pivots sur ce lieu de tir : il domine de peu Anthony Davis mais surclasse Tim Duncan, avec un taux de réussite plus de 2 fois supérieur !

Il est évident que Tim Duncan était en grande difficultés lorsqu'il s'agissait de prendre un tir derrière l'arc, ce qui peut expliquer le fait qu'il ait tenté aussi peu de tirs ici dans sa carrière (seulement 0,65 %) ...

On peut en revanche se demander pourquoi Pau Gasol ne prenait pas plus de tirs depuis cette zone (seulement 1,88 %), au vu de son très bon taux de réussite, à moins que ce ne soit l'inverse, et que ce bon pourcentage s'explique par le faible nombre de tirs tentés ici par le pivot espagnol...

Notons cependant, à la décharge de Tim Duncan que contrairement à Davis par exemple, sa carte de tirs montre des prises de tirs dans des positions extrêmement compliquées derrière l'arc (plus proches de la ligne médiane que de l'arc), ce qui a sûrement contribué à baisser son pourcentage de réussite ici.

⇒ **Corners** : les tirs tentés dans les 2 corners sont trop peu nombreux pour pouvoir juger de l'efficacité réelle des pivots dans cette zone.


BILAN PIVOTS :

Les habitudes de tirs de nos pivots sont assez similaires : la zone restrictive et la zone à mi-distance sont leurs lieux de tirs privilégiés, ce qui est attendu pour un joueur jouant au poste de pivot. Cependant, une différence importante survient lorsque l'on regarde les tirs pris derrière l'arc des 3 points : cette différence est sûrement le signe d'un changement d'époque, puisqu'Anthony Davis fait partie de cette jeune génération de joueurs modernes, envers qui les recruteurs et entraîneurs exigent une grande polyvalence dans le jeu plutôt qu'une spécialisation dans un secteur de jeu en particulier, comme c'était plus le cas avant : le joueur de basket américain doit être plus "professionnel" qu'auparavant.

Cela se confirme également avec les taux de réussite au tir, plutôt très bons pour Davis dans toutes les zones sans exception, alors que Tim Duncan était relativement peu à l'aise derrière l'arc.

3.1.2. Les meneurs

Comparaison en termes de **fréquence de tirs tentés par zone** :



Extrait des cartes de tirs de 4 des 7 meneurs de jeu étudiés.

On peut distinguer **3 catégories de meneurs** ici :

- ⇒ Les meneurs de jeu **modernes des années 2010**, qui adorent prendre énormément de tirs au loin : c'est le cas de **Stephen Curry** et **Damian Lillard**. Ces joueurs font partie de la génération "Moreyball", un style de jeu né dans les années 2010 et créé par l'ex-Manager général des Houston Rockets **Daryl Morey** consistant à monter la balle le plus vite possible vers l'avant avant que la défense ne soit repliée, afin de trouver un shoot ouvert au plus près du panier ou à 3 points.

Dans cette philosophie de jeu, le tir à mi-distance est banni au profit du tir à 3 points, suite à un constat très simple réalisé par Morey : la probabilité de marquer un tir à mi-distance (donc à 2 points) n'étant pas très différente de la probabilité de marquer un tir pris derrière l'arc (donc à 3 points) mais les paniers à 2 points rapportant 1.5 fois moins de points que les paniers à 3 points ($3/2 = 1.5$), il est plus rentable de tenter sa chance à 3 points. Autrement dit, bien que la probabilité qu'un tir soit marqué diminue avec l'augmentation de la distance de tir, ce déficit de probabilité est largement en faveur du tir à 2 points est compensé par le nombre de points que rapporte un panier à 3 points à l'équipe.

Ce principe de jeu est parfaitement illustré par les Rockets des années 2010, dont la figure de proue du projet se nommait James Harden.

Constatant que cette philosophie de jeu fonctionne (en tout cas en saison régulière), beaucoup d'autres franchises NBA se sont mises à suivre cet exemple, et notamment les Warriors de Stephen Curry, mais de manière moins extrême que pour les Rockets.

Un autre phénomène intéressant réside dans l'élaboration par la NBA de règles visant à rendre ce sport spectaculaire depuis des années : et selon la NBA, cela passe par l'attaque.

Ainsi, tout est fait pour que l'attaque soit au centre des matchs NBA, que le jeu soit rapide, que les séquences offensives se multiplient, avec par exemple l'évolution de la règle sur les rebonds offensifs il y a quelques saisons : si un tir est manqué et récupéré par un coéquipier (rebond offensif), l'équipe dispose de seulement 14 secondes (au lieu de 24 secondes auparavant) pour aller marquer un panier. L'objectif étant de ne pas voir une équipe s'éterniser en attaque.

On voit donc bien la prédominance des tirs pris derrière l'arc (part de quasiment 40 % des tirs pour les deux joueurs).

Notons que les tirs à mi-distance sont assez fréquents, et loin d'être bannis comme on voulait le faire chez les Rockets.

Cependant, Curry et Lillard se distinguent sur un point important : les tirs dans la zone restrictive. Lillard prend souvent ses tirs dans cette zone (30 % du temps), c'est même la 2ème zone dans laquelle il prend le plus de tirs alors que Curry ne tire que 20 % du temps ici, et privilégie plutôt la zone mi-distance (22 % du temps).

De plus, Curry se distingue de tous les autres meneurs par ses prises de tirs plus importantes que pour les autres joueurs dans les corners.

- ⇒ Les meneurs de jeu de **l'ancienne ère de la NBA** sont composés de **Allen Iverson**, **Steve Nash** et **Tony Parker** : les 2 premiers ont débuté en NBA lors de la saison 1996-1997, alors que Tony Parker n'a débuté qu'en 2001-2002. Leurs prises de tirs diffèrent grandement des 2 meneurs étudiés précédemment.

Iverson et Nash ont des profils assez similaires sur certains points : ils prennent beaucoup de tirs à mi-distance (ce que l'on cherche au maximum à éviter de nos jours) et dans la zone


restrictive : leur "petit" gabarit (1.83 m pour Iverson, 1.91 m pour Nash) favorisait un jeu tout en pénétration, et donc la prise de tir au plus proche du panier.

Cependant, Nash se distingue d'Iverson par une prise de tirs importante (quasiment le double d'Iverson) derrière l'arc des 3 points : la cause de cette observation est un principe précurseur du "Moreyball" (déjà évoqué plus haut), appelé "7 seconds or less". Ce style de jeu prône, comme son nom l'indique, une prise de tir rapide survenant moins de 7 secondes après qu'une équipe ait récupéré la balle, alors que la défense adverse n'est pas encore replacée. Steve Nash ayant joué pour les Suns de Phoenix durant une grande partie de sa carrière sous la houlette de Mike D'Antoni, l'entraîneur à l'origine de ce principe de jeu, il n'est pas étonnant de constater sa prise d'initiative importante à 3 points.

Bien qu'appartenant à la même "génération", Tony Parker différait de ses 2 compatriotes : il prenait très peu de tirs derrière l'arc (seulement 6 % du temps), mais énormément au plus près du panier (zone restrictive, raquette) et à mi-distance. Curieusement, sa carte de tirs est très similaire à celle du pivot Anthony Davis, que nous avons décrypté précédemment, bien que ces 2 joueurs n'aient rien de comparable !

- ⇒ Les meneurs de **l'entre deux** sont ceux ayant joué en NBA entre les 2 périodes décrites ci-dessus. On y trouve un seul joueur : **Chris Paul**.
- ⇒ Enfin, **Russell Westbrook** est un meneur de jeu moderne au jeu assez atypique : bien qu'ayant une taille modeste (1.91 m) similaire à Steve Nash et Stephen Curry par exemple, son jeu très explosif voire même brutal favorisant le contact en fait un meneur bien différent des autres, comme en témoigne sa carte de tirs : assez peu de tirs tentés derrière l'arc des 3 points (seulement 18 %, à comparer aux 40 % de Lillard et Curry, les 2 autres joueurs de sa génération) mais énormément de tirs pris dans la zone restrictive, la raquette et à mi-distance. Son jeu tout en puissance le pousse à énormément porter le ballon et jouer sur son physique, même face à des joueurs au gabarit souvent beaucoup plus impressionnant que le sien, comme l'illustrent les dunks impressionnants qu'il est capable de marquer. Nous pouvons même dire que son style de jeu est totalement opposé à celui d'un Stephen Curry.

Comparaison en termes de réussite au tir par zone :



Extrait des cartes de tirs de 2 des 7 meneurs, en termes de taux de réussite au tir par zone.

- ⇒ **Zone restrictive (orange) : Steve Nash** est le meneur le plus efficace au tir dans cette zone : il devance de très peu Tony Parker et Stephen Curry. En revanche, **Damian Lillard** n'est qu'à 55 % de réussite dans cette zone.

- ⇒ **Raquette** (vert) : **Chris Paul** est de loin le plus efficace dans la raquette, avec près de 49 % de réussite au tir dans cette zone. Ce pourcentage est même meilleur que celui des 3 pivots étudiés, qui tournaient autour de 43 % de réussite ici !

Steve Nash et Tony Parker suivent avec respectivement 46 % et 44 % de réussite.

En revanche, une nouvelle fois, **Damian Lillard** occupe la dernière position de ce classement avec seulement **34 % de réussite**.

- ⇒ **Mi-distance** (violet) : le trio de tête se compose de **Steve Nash**, **Chris Paul** et **Stephen Curry**, qui tournent respectivement à 47 %, 46 % et 45 % de réussite au tir dans cette zone.

En revanche, Allen Iverson et Russell Westbrook sont les derniers de la classe sur ce spot de tir, alors qu'ils prennent une part assez conséquente de leurs tirs dans cette zone !

- ⇒ **Arc des 3 points** (marron) : Bien que Stephen Curry soit considéré comme l'un des meilleurs tireurs à 3 points de l'histoire, **Steve Nash** le domine de très peu en termes de réussite au tir derrière l'arc des 3 points, les deux joueurs tournant à 42 % de réussite.

A contrario, Tony Parker ne parvient pas à dépasser les 30 % de réussite à 3 points et se classe en dernière position sur ce spot de tir. On comprend dès lors mieux pourquoi seulement 6 % de ses tirs étaient tentés ici...

- ⇒ **Corner gauche** : **Stephen Curry** est non seulement celui qui tente le plus de tirs dans ce corner, mais également celui qui y est le plus efficace avec un taux de réussite de 50 %, une nouvelle fois devant Steve Nash avec 49 %.


Russell Westbrook ferme la marche de ce classement, avec seulement 32 % de réussite.

- ⇒ **Corner droit** : comme pour le corner gauche, **Stephen Curry** domine ses adversaires tant sur le nombre de tirs tentés que sur le taux de réussite dans ce coin, avec quasiment 50 % de réussite, loin devant Steve Nash avec 40 %.

Le mauvais élève se nomme une nouvelle fois Russell Westbrook, avec 29 % de réussite.

3.1.3. Les arrières

Comparaison en termes de **fréquence de tirs tentés par zone** :



Extrait de la carte de tirs de 4 des 6 arrières, en termes de fréquence de tir par zone.

On observe des cartes très différentes selon les joueurs :

- ⇒ **Kobe Bryant** avait une zone de tir privilégiée et clairement identifiable : **la zone de mi-distance**, dans laquelle 41 % de ses tirs était pris ! C'est le même pourcentage que pour Allen Iverson (meneur), les 2 joueurs ayant commencé à jouer en NBA la même saison et ayant joué durant 17 saisons communes !

Ensuite, Bryant tire dans des proportions assez proches dans la zone restrictive et derrière l'arc (entre 18 % et 23 %), et un peu moins fréquemment dans la raquette (14 %). Il est en revanche l'un des arrières tentant le moins souvent sa chance dans les corners.

- ⇒ **Ray Allen**, au cœur des débats sur le meilleur tireur à 3 points de l'histoire avec Stephen Curry, ne prenait pas tant de tirs derrière l'arc que ce que l'on peut penser (seulement 28 % derrière l'arc, contre 41 % pour Curry et Harden par exemple). Il tirait quasiment la même proportion de ses tirs à mi-distance, et est le joueur de la liste des 20 joueurs qui tentait le plus sa chance dans les corners avec une proportion de 10 %, corners gauche et droit confondus (pour la petite anecdote, un de ses tirs les plus célèbres reste le panier marqué avec Miami dans le

corner droit, à quelques secondes de la fin du match 6 des NBA Finals 2013 face aux Spurs de San Antonio, ayant permis au Heat d'aller en prolongation puis de gagner ce match historique).

- ⇒ **Paul Pierce** n'avait pas réellement de zone de tir privilégiée, et était plutôt polyvalent : il prenait ses tirs aussi régulièrement de très proche (zone restrictive) qu'à mi-distance et qu'à longue distance (arc des 3 points).

En revanche, il délaissait quelque peu la raquette par rapport aux autres spots de tir, avec seulement 9 % de ses tirs pris dans la raquette.

- ⇒ **Manu Ginobili** possède une carte de tirs assez similaire à celle de James Harden : l'argentin privilégiait la prise de tir soit très proche du panier (zone restrictive, 1/3 du temps), soit à longue distance (derrière l'arc, quasiment 1/3 du temps). La raquette et la zone de mi-distance n'étaient pas délaissées, mais il y prenait beaucoup moins de tirs que dans les 2 premières zones citées.

Derrière Allen et Curry, il est celui qui tente également la plus grande part de tirs dans les corners.

- ⇒ **Dwyane Wade** possédait des habitudes de tirs très différentes des autres arrières étudiés ici : sa carte de tirs ressemble de près à celle de Tony Parker (meneur). A l'instar de Manu Ginobili, il privilégiait 2 zones de tirs en particulier, mais pas les mêmes zones que Ginobili : les tirs très proches (zone restrictive) et les tirs mi-distance.

En revanche, pour ce qui est des tirs longue distance, Wade présente un très faible pourcentage avec seulement 9 % de ses tirs tentés

- ⇒ Comme expliqué plus haut lors de l'analyse des meneurs, **James Harden** symbolise à lui seul le principe du "Moreyball" : seulement 12 % de ses tirs sont pris à mi-distance (LE tir banni par ce principe de jeu moderne), et la majeure partie de ses tirs sont pris soit à 3 points (41 % derrière l'arc, 4 % dans les corners), soit au contact du panier dans la zone restrictive (30,46 %).

Comparaison en termes de réussite au tir par zone :

- ⇒ **Zone restrictive (orange) :**
Top 3 : Wade (64,42 %) - Bryant (62,37 %) - Allen (60,74 %)
Flop : Pierce (58,76 %)
- ⇒ **Raquette (vert) :**
Top 3 : Bryant (45,01 %) - Wade (43,35 %) - Allen (42,69 %)
Flop : Harden (36,73 %)
- ⇒ **Mi-distance (violet) :**
 - ⇒ Top 3 : Allen (42,32 %) - Bryant (40,55 %) - Pierce (40,41 %)
 - ⇒ Flop : Ginobili (35,83 %)
- ⇒ **Arc des 3 points (marron) :**
Top 3 : Allen (39,1 %) - Ginobili (36,59 %) - Pierce (36,51 %)
Flop : Wade (29,59 %)
- ⇒ **Corner gauche :**
Top 3 : Allen (44,53 %) - Ginobili (40,21 %) - Pierce (38,72 %)
Flop : Wade (34,43 %)
- ⇒ **Corner droit :**
Top 3 : Allen (42,25 %) - Pierce (38,82 %) - Harden (37,57 %)
Flop : Wade (34,29 %)

BILAN MENEURS :


Ray Allen est systématiquement dans le top 3 en termes d'efficacité : il est très précis quel que soit la zone du terrain dans laquelle il prend son tir, et ce n'est donc pas pour rien qu'il est considéré comme l'un des meilleurs tireurs de l'histoire de la NBA.

A noter également que Kobe Bryant n'apparaît dans le top 3 que pour les zones de tirs proches du panier ou à mi-distance : il ne fait pas partie des meilleurs tireurs à 3 points, ce qui peut expliquer pourquoi il ne tentait pas une part faramineuse de ses tirs à 3 points.

Enfin, Dwyane Wade est en dernière position dans tous les secteurs de tirs longue distance (corners + arc) : cela traduit des difficultés encore plus importantes que Kobe sur les tirs longue distance.

3.1.4. Les ailiers | ailiers forts

Comparaison en termes de fréquence de tirs tentés par zone :



- ⇒ **LeBron James** privilégie 2 zones de tir en particulier : la **zone restrictive** et la **zone mi-distance**. Au vu de son physique et de son style de jeu tout en puissance et en "enfonceur" du défenseur adverse, rien de très surprenant à cela puisqu'aucun joueur de la ligue n'est en mesure de le stopper une fois qu'il est lancé vers le panier, encore aujourd'hui à 37 ans !

Malgré cela, ses prises de tirs derrière l'arc des 3 points sont loin de représenter une part négligeable de ses prises de tir, avec 20 % du total de ses tentatives. Notons cependant la dispersion des points représentant ses tirs derrière l'arc, pour certains très éloignés de l'arc !

- ⇒ **Kevin Durant** possède comme LeBron James les 2 mêmes zones de tirs préférentielles, mais pas dans le même ordre : Durant tire en priorité à mi-distance (35 % du temps) et ensuite dans la zone restrictive (23 % du temps).

Comparé à James, il tire plus régulièrement derrière l'arc et y est sûrement plus à l'aise pour tirer que LeBron au vu de l'aisance et la fluidité du tir de Durant sur ce spot. LeBron James quant à lui possède un tir beaucoup moins "naturel" derrière l'arc, qui s'est fluidifié avec le temps mais qui était loin d'être parfait au début de sa carrière, ou il lui arrivait parfois d'envoyer quelques "briques" contre la planche.

- ⇒ **Giannis Antetokounmpo** est quant à lui l'archétype même du joueur puissant : sûrement l'un des plus puissants (si ce n'est le plus puissant) joueur de la ligue actuel, il cherche presque systématiquement à faire la différence sur son défenseur par la force, en enfonçant son défenseur qui ne peut alors rien faire, en témoigne sa carte de tirs : 54 % de ses tirs sont pris dans la zone restrictive !

C'est même le seul joueur de la liste des 20 qui prend plus de 50 % de ses tirs dans une seule zone ! Sa part de tentatives derrière l'arc est assez faible, plus de 2 fois inférieure à celle de James et sa part de tirs mi-distance n'est pas très élevée non plus (14 %) : on voit donc assez aisément avec cette carte quel type de jeu produit Giannis Antetokounmpo sur le terrain.

- ⇒ **Kawhi Leonard** est le seul "ailier de formation" parmi ces 4 joueurs, les 3 autres étant avant tout des ailiers forts. Sa carte de tirs est assez proche de celle de Kevin Durant, mais les pourcentages associés sont plus resserrés que pour Durant, ce qui traduit une plus grande indifférence de la part de Kawhi dans la position de tir : il tire quasiment autant de fois depuis la zone restrictive, qu'à mi-distance ou derrière l'arc.

En revanche, il se distingue de ses homologues par ses prises de tirs plus fréquentes dans les corners, quasiment équivalentes à celle de Manu Ginobili (arrière).

Comparaison en termes de réussite au tir par zone :

On retrouve quasiment systématiquement le même top 3 et dans le même ordre, quel que soit la zone de tir :

1- Kawhi Leonard | 2- Kevin Durant | 3- LeBron James

Giannis Antetokounmpo est quasiment en dernière position dans toutes les zones et présente de plus des pourcentages assez éloignés de ses acolytes ! Même dans la zone restrictive, dans laquelle on rappelle qu'il prend 54 % de ses tirs, son efficacité ne surpasse pas celle de James et Durant...

Il est malgré tout parvenu à être élu MVP de la saison régulière lors des 2 dernières saisons NBA, et à remporter un titre NBA la saison passée avec son équipe des Milwaukee Bucks...

3.1.5. Synthèse

3 profils de "shooteur" semblent se dessiner :

- ⇒ Ceux qui tirent dans la **raquette** et à **mi-distance**.
- ⇒ Ceux qui tirent dans la **raquette** et à **3 points**.
- ⇒ Ceux qui tirent **sous le panier**.

- ⇒ **Parmi les meneurs :**
 - Ceux qui tirent dans la raquette et à mi-distance : Allen Iverson, Tony Parker, Dwyane Wade, Chris Paul.
 - Ceux qui tirent dans la raquette et à 3 points : Russell Westbrook, James Harden, Stephen Curry, Damian Lillard, Steve Nash.

- ⇒ **Parmi les ailiers :**
 - Ceux qui tirent dans la raquette et à mi-distance : Kobe Bryant, Kevin Durant.
 - Ceux qui tirent dans la raquette et à 3 points : LeBron James, Manu Ginobili, Kawhi Leonard.

- ⇒ Les **pivots** tirent en règle générale dans la raquette ou à proximité, très rarement au-delà de l'arc des 3 points.

La réussite d'un tir :

- ⇒ La réussite "sous" le panier est commune à tous les profils de joueurs.
- ⇒ La réussite à 3 points n'est significative que pour certains joueurs (Stephen Curry, Ray Allen).
- ⇒ La réussite à mi-distance semble être en faveur des ailiers.

4. Prédiction de l'issue d'un tir pour les 10 joueurs en activité

4.1. Pourquoi regrouper les joueurs selon leur poste ?

L'idée initiale de ce projet était de créer 1 modèle de prédiction de tirs par joueur : chacun ayant son style de jeu bien à lui, ses tirs préférentiels et ses particularités, tenter de développer un modèle par joueur semblait être la meilleure chose à faire dans la mesure où l'on pensait que la prédiction faite par le modèle n'en serait que plus précise et proche de la réalité, car adaptée au joueur concerné.

Cependant, pour certains joueurs comme James Harden ou encore Kawhi Leonard, il s'est avéré extrêmement difficile d'augmenter la performance du modèle.

Bien que les 10 joueurs choisis soient des top joueurs de la NBA moderne, leur profil de jeu ainsi que l'espace de jeu qu'ils occupent sur le terrain en attaque sont très différents d'un joueur à un autre : un pivot est souvent cantonné à jouer à l'intérieur de la ligne des 3 points, et ne ressort normalement que rarement derrière cette ligne pour prendre ses tirs, alors que le poste d'arrière par exemple est plutôt "mixte", dans le sens où il peut tout aussi bien jouer et prendre ses tirs à l'intérieur qu'à l'extérieur de cette ligne des 3 points. Il en résulte par exemple que les prises de tirs de Giannis Antetokounmpo (27 ans, 2.11 m, 110 kg, poste d'ailier fort) et de James Harden (32 ans, 1.96 m, 100 kg poste d'arrière) n'ont pas grand-chose en commun, de même que leur réussite au tir : ainsi, la finalité de leur tir (marqué ou raté) ne dépend pas forcément des mêmes paramètres, et il est sans doute préférable de sélectionner les variables du modèle en fonction du profil de joueur en vue d'obtenir de meilleures performances pour notre modèle.

Malgré tout, les analyses ont révélé que des joueurs jouant au même poste présentent des similitudes dans leurs prises de tir.

De plus, il est extrêmement long et fastidieux de devoir créer un modèle par joueur : comment aurions-nous fait s'il avait fallu créer un modèle pour chaque joueur actuel de la ligue ?

Dans notre recherche d'efficacité, en vue de réduire le nombre d'analyses à effectuer, le nombre de modèles à développer et donc le temps de calcul de l'ordinateur, et la mise à jour/la maintenance des modèles, il paraissait plus sage de choisir de regrouper les joueurs du même poste dans un seul et même modèle.

4.2. Le choix de la métrique de classification

Le choix de la métrique pour nos modèles a été guidé par cette question : qu'est-ce qu'un bon modèle de classification d'issues de tirs NBA ?

Afin d'y répondre, il faut se s'imaginer être dans les 2 cas de figures suivants :

- ⇒ CAS 1 : Supposons que mon modèle prédit qu'un tir de Kévin Durant ne rentrera pas (prédit 0), alors qu'en réalité, il rentre (observé 1) : nous sommes donc en présence d'un **FAUX NÉGATIF**.

Quelle conséquence ?

- ⇒ Selon mon modèle, un tir pris dans ces conditions par Durant ne rentrera pas : je vais donc dire à mes joueurs de ne pas trop se focaliser à défendre sur Durant, de le "laisser tirer", pour agir autrement en défense : sauf qu'en réalité, Durant marque !
- ⇒ Mon modèle détecte mal les individus positifs : il a une mauvaise sensibilité. Les conséquences sont assez dramatiques, puisque croyant systématiquement (à cause de mon modèle) que le tir ne rentrera pas, je vais moins défendre sur Durant, mais celui-ci va en réalité être libre de marquer la plupart du temps : je vais encaisser énormément de points "gratuitement" !
- ⇒ CAS 2 : Supposons maintenant que mon modèle prédit qu'un tir de Kévin Durant rentrera (prédit 1), alors qu'en réalité, il ne rentre pas (observé 0) : nous sommes donc en présence d'un **FAUX POSITIF**.

Quelle conséquence ?

- ⇒ Selon mon modèle, un tir pris dans ces conditions par Kevin Durant rentrera : je vais donc dire à mes joueurs d'adapter leur défense sur Durant, et de faire pression sur lui plus fortement que sur un autre joueur, de "délaisser" un peu les autres joueurs : sauf qu'en réalité, Durant ne marquerait pas !
- ⇒ Mon modèle détecte mal les individus négatifs : il a une mauvaise spécificité. Les conséquences sont légèrement moins dramatiques que dans le 1er cas, mais elles peuvent être terribles puisque croyant systématiquement (à cause de mon modèle) que le tir rentrera, je vais demander à mes joueurs de plus se focaliser en défense sur Durant, mais celui-ci, sachant qu'il marquait déjà plus difficilement dans ce contexte, se sachant serré de près et n'étant pas mauvais pour délivrer de passes décisives à ses équipiers par exemple, va pouvoir tenter d'exploiter d'éventuels "errements" de la défense sur ses coéquipiers (qui ne sont pas des amateurs...), afin de faire marquer facilement un de ses équipiers : je peux potentiellement encaisser pas mal de points "gratuitement" aussi !

BILAN : il faut donc à la fois que mon modèle ait une bonne sensibilité ET une bonne spécificité : nous allons donc utiliser le score F1 (moyenne harmonique de la spécificité et de la précision) comme métrique d'évaluation pour nos modèles.

4.3. Répartition des tâches entre les membres du groupe

- Benjamin : création du modèle pour le groupe des ailiers forts | pivots (Giannis Antetokounmpo, Anthony Davis)
- Cyrille : création du modèle pour le groupe des meneurs (Chris Paul, Stephen Curry, Damian Lillard, Russell Westbrook et James Harden)
- Julien : création du modèle pour le groupe des ailiers | ailiers forts (LeBron James, Kevin Durant)

4.4. La procédure d'évaluation des modèles

Afin de ne pas déroger à la règle stipulant qu'un modèle ne doit jamais avoir accès aux données de test avant son évaluation finale et d'évaluer à leur juste valeur nos modèles, nous avons défini une procédure d'évaluation unique et fiable qui sera appliqué à tous les modèles qui seront testés et comparés entre eux :

- 1- Création d'un jeu d'entraînement (80 % du total des données) et de test (20 % du total des données).
 - La graine aléatoire (random state) de la fonction `train_test_split` est fixée à 0, afin que lors de chaque exécution, la composition des jeux d'entraînement et de test ne change pas.
 - Le jeu de test est mis de côté et ne sera touché qu'à la toute fin, pour évaluer le meilleur modèle trouvé.
- 2- Application d'une validation croisée par méthode des K folds sur le jeu d'entraînement : calcul du recall moyen, de la précision moyenne et du f1-score moyen obtenus sur chaque fold et tracer, dans une grille, des courbes représentant le score obtenu (recall, précision ou f1-score) en fonction du fold de la validation croisée.

Nous avons donc une grille avec 3 graphiques (1 graphique par métrique), et 2 courbes par graphique (courbe des résultats d'entraînement et courbe des résultats de test).

Ainsi, on peut observer la présence d'un éventuel sur-apprentissage en regardant l'écart entre les 2 courbes d'un même graphique, et comparer les performances de nos modèles grâce aux moyennes de scores calculées.

4.5. Démarche de travail

Dans notre quête de recherche du modèle le plus performant possible, la démarche de travail utilisée a été la suivante (parfois, suivant les résultats obtenus, quelques-unes de ces étapes n'ont pas été réalisées) :

4.5.1. Test d'un premier modèle

Création d'un 1er modèle d'arbre de décision avec la combinaison de toutes les variables explicatives pour lesquelles il a été démontré lors analyses qu'elles sont significativement liées à la variable cible.

4.5.2. Réglage du jeu de données

Cette étape consiste en la recherche des données à utiliser pour entraîner notre modèle afin de réduire au maximum le sur-apprentissage.

A ce stade, le but n'est pas tant la recherche d'optimisation de la performance pure du modèle, mais plutôt la recherche du jeu d'apprentissage optimal afin d'obtenir un modèle robuste, qui ne sur-apprend ni ne sous-apprend. Pour cela, nous utilisons un modèle "bateau" d'arbre de décision, réputé pour être particulièrement sensible au sur-apprentissage : si nous parvenons à réduire le sur-apprentissage avec un tel type de modèle, il y a fort à parier qu'avec un autre type de modèle, le sur-apprentissage soit tout aussi réduit.

Cette étape se décompose en deux parties :

⇒ Sélection des variables

On recherche ici manuellement ou à l'aide d'outils de sélection de variables, une ou plusieurs combinaisons de variables explicatives prometteuses, c'est-à-dire permettant au modèle de ne pas sur-apprendre ET permettant également au modèle d'avoir un bon compromis entre recall et précision.

⇒ Recherche de données aberrantes

Ici, on se réfère aux analyses effectuées pour détecter d'éventuelles valeurs aberrantes qui pourraient potentiellement fausser les prédictions du modèle.

Cependant, très peu voire parfois aucune donnée n'était aberrante.

De plus, "La suppression des données aberrantes est une pratique controversée désapprouvée par de nombreux scientifiques et professeurs ; tant qu'il n'y aura pas de critères mathématiques permettant d'offrir une méthode objective et quantitative pour le rejet de valeurs, il sera impossible de rendre la pratique de suppression des données aberrantes scientifiquement et méthodologiquement plus acceptable." ([Extrait de Wikipédia, Donnée aberrante — Wikipédia \(wikipedia.org\)](#)).

C'est pourquoi, dans ce projet, toutes les données ont été conservées, hormis un faible nombre de lignes lors de la suppression des catégories de tir très rares (variable "action type) lors du nettoyage des données.

4.5.3. Recherche des types de modèles prometteurs

Ici, nous entraînons 4 types de modèles de classification classiques : random forest, KNN, régression logistique et SVM avec la combinaison de variables choisies et les données d'entraînement choisies en 4.4.2-, par validation croisée.

Suivant la présence de sur-apprentissage et les performances de base en termes de recall et précision, nous en déduisons quels sont les types de modèles qui valent le coup d'être optimisés au niveau des hyperparamètres.

4.5.4. Optimisation d'hyper paramètres par GridSearch

Nous tentons ensuite, lorsque cela est possible (parfois extrêmement long pour les SVM, donc n'aboutissant pas), de rechercher la meilleure combinaison d'hyperparamètres possible par recherche par grille pour chaque type de modèle sélectionné lors de l'étape 4.5.3).

4.5.5. Comparaison des types de modèles optimisés

Un fois fait, nous réentraînons et évaluons une dernière fois les types de modèles optimisés à l'aide de notre procédure d'évaluation, puis comparons leurs performances : le modèle choisi sera celui présentant le meilleur compromis entre recall et précision et présentant le recall le plus élevé.

Si les résultats obtenus pour notre modèle après ces 5 étapes ne sont pas suffisamment bons, les étapes 4.5.3) / 4.5.4) / 4.5.5) pourront être répétées avec une autre combinaison de variables prometteuse, et d'autres techniques d'amélioration de modèles pourront éventuellement être utilisées (réduction de dimension, rééquilibrage des classes, sélection non manuelle des variables explicatives ...).

4.5.6. Evaluation finale

Enfin, nous entraînons le modèle avec la combinaison de variables choisis sur le jeu d'entraînement tout entier, puis nous l'évaluons sur le jeu de test, qui a été mis de côté depuis le début et qui comprend des données jamais vues par le modèle, simulant ainsi les performances réelles que pourrait avoir notre modèle.

5. Modélisation

5.1.1. Les groupes de joueurs

Comme évoqué précédemment, nous avons regroupé les joueurs dans trois groupes selon leurs postes pour nos modélisations :

	 LeBron James	 Kevin DURANT	 Stephen CURRY	 Chris PAUL	 Russel WESTBROOK
Age	37 ans	33 ans	34 ans	36 ans	33 ans
Taille	2,06 m	2.08 m	1.88 m	1.83 m	1.91 m
Poids	113 kg	109 kg	84 kg	79 kg	91 kg
Franchise	Cleveland Cavaliers, Miami Heat, Los Angeles Lakers	Oklahoma City Thunder, Golden State Warriors, Brooklyn Nets	Golden State Warriors	Suns de Phoenix, Thunder d'Oklahoma City, Rockets de Houston, Clippers de Los Angeles, Hornets de La Nouvelle-Orléans	Thunder d'Oklahoma City, Rockets de Houston, Wizards de Washington, Lakers de Los Angeles
Titres NBA	4 (2012, 2013, 2016, 2020)	2 (2017, 2018)	3 (2015, 2017, 2018)	0	0
MVP de la saison	4 (2009, 2010, 2012, 2013)	1 (2014)	2 (2015, 2016)	0	1 (2017)
MVP des finals	4 (2012, 2013, 2016, 2020)	2 (2017, 2018)	0	0	0
Moy. Pts / match	27.1 points (5ème all time)	27,1 points (4ème all time)	25 points	18 points	23 points
Groupe	Ailiers Ailiers forts	Ailiers Ailiers forts	Meneurs	Meneurs	Meneurs
	 Damian LILLARD	 James HARDEN	 Anthony DAVIS	 Giannis ANTETOKOUNMPO	
Age	33 ans	32 ans	29 ans	27 ans	
Taille	1.88 m	1.96 m	2.08 m	2.11 m	
Poids	88 kg	100 kg	115 kg	110 kg	
Franchise	Trail Blazers de Portland	Thunder d'Oklahoma City, Rockets de Houston, Nets de Brooklyn, 76ers de Philadelphie	Hornets de La Nouvelle-Orléans, Los Angeles Lakers	Filathlitikos B.C., Bucks de Milwaukee	
Titres NBA	0	0	1 (2020)	1 (2021)	
MVP de la saison	0	1 (2018)	0	2 (2019, 2020)	
MVP des finals	0	0	0	1 (2021)	
Moy. Pts / match	24.5 points	25 points	23.8 points	21.7 points	
Groupe	Meneurs	Meneurs	Pivots Ailiers forts	Pivots Ailiers forts	

5.1.2. Analyses

Comme nous avons regroupé les données des joueurs par groupe afin de créer un modèle par type de poste, l'analyse préalable a été réalisée sur les données communes à chaque groupe de joueurs, et non séparément.

Après filtrage des données, nous disposons de trois jeux de données extrêmement propres, composés de **21 variables** et **124 994 lignes**

(Ailiers | Ailiers fort : **48 112** lignes

Meneurs : **59 805** lignes

Pivots | Ailiers forts : **17 077** lignes).


Aucune valeur manquante n'est à signaler, idem pour les doublons :

	player name	team name	conference	division	adversary	conference adv	division adv	game date	season type	home	...	time remaining	location x	location y	shot distance	action type	shot type
52883	lebron james	CLE	est	centrale	SAC	ouest	pacifique	2003-10-29	regular season	0	...	8.56	15.8	0.0	15.800000	jump shot	2
52884	lebron james	CLE	est	centrale	SAC	ouest	pacifique	2003-10-29	regular season	0	...	7.44	-13.1	0.2	13.101527	jump shot	2
52885	lebron james	CLE	est	centrale	SAC	ouest	pacifique	2003-10-29	regular season	0	...	7.01	16.3	0.5	16.307667	fadeaway	2
52886	lebron james	CLE	est	centrale	SAC	ouest	pacifique	2003-10-29	regular season	0	...	6.29	-11.8	9.2	14.962620	jump shot	2
52887	lebron james	CLE	est	centrale	SAC	ouest	pacifique	2003-10-29	regular season	0	...	4.48	5.4	2.2	5.830952	jump shot	2

Extrait du haut d'un des trois jeux de données.


La visualisation de la variable cible "shot made flag" nous permet de constater que la répartition entre les tirs marqués et ratés reste équilibré dans nos trois jeux de données, avec un ratio de quasiment 50 % de tirs marqués versus 50 % de tirs ratés à chaque fois :

Composition de la variable 'shot made flag'.




Répartition de "shot made flag" pour df_james_durant (groupe des ailiers/ailiers forts).

Ensuite, le point le plus important est l'analyse des relations entre variables, et particulièrement entre la variable cible et les potentielles variables explicatives du modèle. Grâce aux visualisations effectuées, certaines hypothèses ont pu être émises quant aux potentiels liens existants entre "shot made flag" et les autres variables du jeu de données :



Extrait des visualisations entre la cible et les variables quantitatives : influence de la finalité du tir sur le temps restant à jouer et sur la coordonnée x du tireur, pour le groupe des ailiers/ailiers forts

Nombre de tirs marqués/râtés selon les modalités de 'adversary'.



Influence de l'équipe adverse sur la finalité du tir, pour le groupe des ailiers/ailiers forts

Par exemple, il apparait visuellement que la finalité d'un tir pris par Durant ou James est influencée par la distance de tir ("shot distance"), la coordonnée en x ("x location"), la coordonnée en y ("y location"), l'équipe pour laquelle joue le joueur ("team name"), la division dans laquelle joue le joueur ("division"), l'équipe contre laquelle il tente son tir ("adversary"), le quart-temps au cours duquel il tire ("period"), la zone de tir ("shot zone basic"), l'orientation face au panier ("shot zone area"), la valeur du tir pris ("shot type") et le type de tir utilisé ("action type").

Les tests d'hypothèses (ANOVA et khi-2) nous ont ensuite permis de confirmer (ou non) chacune des hypothèses formulées ci-dessus :



- Certaines relations observées visuellement n'ont pas pu être confirmées par le test.
- A contrario, le test ANOVA nous a également révélé l'existence de liaisons insoupçonnées, que nous n'avions pas forcément décelé au travers des graphiques (le lien entre la finalité du tir et le temps restant à jouer dans le quart-temps par exemple [variable "time remaining"]).
- Le test du khi-2 nous a également permis de découvrir de nouvelles associations statistiques significatives entre la finalité du tir et d'autres variables (nom du joueur, conférence dans laquelle il joue, moment de la saison, localisation du match...etc.).


⇒ Ces résultats sont essentiels pour la suite, car nous pouvons dès lors faire une sélection initiale de variables explicatives pour notre 1er modèle, en ne conservant que celles pour lesquelles il a été possible de conclure à un lien statistique significatif avec la cible "shot made flag".

Nous disposons donc d'une combinaison initiale de plusieurs variables explicatives pour chacun de nos modèles par poste.

Le nombre de combinaisons possibles de 2 variables choisies parmi celles sélectionnées étant très important, les analyses des liens entre variables explicatives sont extrêmement nombreuses, et pour certaines peu intéressantes : elles nous permettront cependant, si besoin lors de la modélisation, de retirer de notre combinaison initiale de variables des variables très liées entre elles afin de tenter d'améliorer les performances du modèle.

Voici quelques exemples de relations intéressantes qui ont été relevées visuellement, puis confirmées par un test :






Extraits des relations entre variables explicatives, pour le groupe des ailiers/ailiers forts.

Une fois les jeux de données préparés (filtrage des variables explicatives, catégorisation des variables numériques, dichotomisation des variables catégorielles), nous nous retrouvons avec un total de plusieurs dizaines de variables (entre 79 et 86 suivant le jeu de données).

Pour nos trois modèles, nous avons décidé de commencer par un modèle très basique d'**arbre de décision**, entraîné et évalué par validation croisée grâce à la procédure d'évaluation décrite plus haut, avec cette combinaison de variables explicatives liées à la cible :



Les performances obtenues par le modèle d'arbre de décision pour le groupe des **ailiers/ailiers forts**, avec la combinaison de variables explicatives initiale, en utilisant notre procédure d'évaluation.

⇒ Ce tout premier modèle présente un problème évident de sur-apprentissage ; il y a un écart entre les scores de train et de test (entre 23 % et 25 % selon les jeux de données de chaque groupe de joueurs). Mais il est important de rappeler que les arbres de décision sont un type de modèle réputé comme étant très sensible au sur-apprentissage, et que nous n'avons pas encore cherché à optimiser les performances.

Le compromis entre recall et précision est variable selon nos 3 jeux de données (recall entre 50 % et 64 % ; précision entre 51 % et 62 %)

Nous nous sommes ensuite lancés dans la recherche d'une ou plusieurs combinaisons des variables liées à la cible permettant de totalement gérer les problèmes de sur-apprentissage, sans forcément chercher à optimiser la performance pure (c'est-à-dire le f1-score), mais tout en ayant malgré tout une performance de base suffisamment bonne.

Pour cela, nous avons commencé par effectuer une sélection manuelle de variables : après quelques essais successifs de combinaisons de variables basée sur notre intuition et notre connaissance amateur du basketball, nous avons créé une fonction permettant de tester par validation croisée toutes les combinaisons possibles de n variables.

	combinaison	recall_test	precision_test	f1_test	abs(f1 train-f1 test)
99	('shot type', 'period', 'player name', 'season...	0.760086	0.540634	0.631655	0.007528
89	('shot type', 'time remaining', 'player name',...	0.737892	0.538670	0.622646	0.009298
87	('shot type', 'time remaining', 'shot zone are...	0.628851	0.603973	0.616141	0.013939
76	('shot type', 'time remaining', 'period', 'sho...	0.638138	0.595415	0.615963	0.024260
119	('time remaining', 'shot zone area', 'player n...	0.649525	0.584408	0.615224	0.013796
88	('shot type', 'time remaining', 'shot zone are...	0.617516	0.607074	0.612214	0.012014
86	('shot type', 'time remaining', 'shot zone are...	0.614052	0.608558	0.611290	0.011992
74	('shot type', 'time remaining', 'period', 'sho...	0.627276	0.596173	0.611279	0.026075
124	('period', 'shot zone area', 'player name', 's...	0.629112	0.592765	0.610333	0.006238
96	('shot type', 'period', 'shot zone area', 'pla...	0.601196	0.617401	0.609165	0.004742
97	('shot type', 'period', 'shot zone area', 'pla...	0.600986	0.616831	0.608735	0.005790
104	('shot type', 'shot zone area', 'player name',...	0.597733	0.619609	0.608446	0.005271
75	('shot type', 'time remaining', 'period', 'sho...	0.615364	0.599063	0.607075	0.023297

Extrait du tableau des résultats obtenus pour le test de toutes les combinaisons possibles de 5 variables.

Après avoir obtenu un tableau (comme ci-dessus) pour les combinaisons de variables, les résultats nous ont permis de dégager une combinaison de 4 ou 5 variables pour chacun des groupes de joueurs qui semblaient prometteuses à optimiser, grâce à leur absence de sur-apprentissage et leurs bonnes performances de base :

- Ailiers | Ailiers forts :

- Variables sélectionnées : **'shot type', 'time remaining', 'shot zone area', 'player name', 'home'**.
- Performance : recall de **63 %**, précision de **60 %**, f1-score de **62 %**.

- Meneurs :

- Variables sélectionnées : **'season type', 'home', 'action type', 'shot zone area'**.
- Performance : recall de **55 %**, précision de **56 %**, f1-score de **55 %**.

- Pivots | Ailiers forts :

- Variables sélectionnées : **'season type', 'home', 'period', 'shot type', 'shot zone area'**.
- Performance : recall de **77 %**, précision de **61 %**, f1-score de **68 %**.

Une fois nos combinaisons sélectionnées, l'étape suivante consistait à chercher à comparer plusieurs types de modèles de classification de base (random forest, KNN, régression logistique et SVM) afin de déceler celui (ou ceux) pour le(s)quel(s) nous allions chercher à optimiser les hyperparamètres.

A la suite d'une recherche par grille des meilleurs hyperparamètres de chaque type de modèle, nous avons réentraîné et évalué les 4 types de modèles à l'aide de notre procédure d'évaluation.

BILAN : après optimisation des hyperparamètres de chaque type de modèle pour chaque groupe de joueurs, nos choix se sont portés sur :

- Ailiers | Ailiers forts : les modèles optimisés ayant des performances relativement proches, et aucun d'eux ne sur-apprenant, notre choix s'est porté sur le **random forest**, plus facile à interpréter et surtout beaucoup moins long à entraîner qu'un modèle de SVM par exemple.
- Meneurs : nous avons choisi de conserver le modèle de **régression logistique**, car les performances du KNN variaient trop d'un échantillon à un autre, et celles de la forêt aléatoire étaient tout simplement inférieures.
- Pivots | Ailiers forts : les modèles ayant des performances relativement proches, et aucun d'eux ne sur-apprenant, notre choix s'est porté sur la **régression logistique**.

⇒ Nous avons également tenté de développer des modèles plus performants en répétant le même processus avec une seconde combinaison de variables explicatives prometteuses, puis avec de la sélection de variables basée sur le poids de chaque variable dans les prédictions effectuées par les modèles (*feature_importance*), sans avoir pour autant obtenu de meilleures performances.

5.1.3. Résultats finaux

Voici les performances finales des modèles de classification retenus afin de prédire l'issue d'un tir tenté par un joueur de NBA :

⇒ Ailiers | Ailiers forts :

Rapport de classification :					
	precision	recall	f1-score	support	
0	0.61	0.58	0.60	4831	
1	0.60	0.63	0.61	4792	
accuracy			0.60	9623	
macro avg	0.60	0.60	0.60	9623	
weighted avg	0.60	0.60	0.60	9623	
Matrice de confusion :					
	pred raté		pred marqué		
obs raté	2809		2022		
obs marqué	1787		3005		

- **Sur 4792 tirs marqués**, 3005 tirs (= **63 %**) sont repérés par le modèle : autrement dit, 37 % des tirs marqués par Durant et James sont classés par le modèle comme étant des tirs ratés.

Concrètement, cela signifie que **dans 37 % des cas, pensant que l'adversaire ne marquera suite aux prévisions du modèle, nous passerons la consigne au défenseur de ne pas trop presser le tireur, qui en réalité marquera.**

- **Sur 5027 tirs prédits marqués** par le modèle, 3005 (= **60 %**) sont réellement des tirs ayant été marqués : autrement dit, 40 % des tirs prédits marqués par le modèle sont en fait des tirs ayant été ratés.

Concrètement, cela signifie que **dans 40 % des cas, pensant que le tireur marquera suite aux prévisions du modèle, nous demanderons au défenseur de mettre une pression maximale**

sur le tireur voire à un autre défenseur de venir en soutien, alors qu'en réalité, le tireur ne marquerait pas dans cette situation : ce qui lui laisse une occasion de déborder son vis-à-vis, ou de délivrer une passe décisive à un équipier libre de tout marquage.

Il est très intéressant de voir que l'on a réussi à obtenir un bon compromis entre recall et précision sans avoir eu à utiliser la variable "action type" dans notre combinaison de variables explicatives : bien que le fait de l'intégrer aurait sûrement permis d'obtenir des meilleures performances au vue de l'importance qu'elle semblait avoir dans les prévisions du modèle, l'ambiguïté qui règne autour de sa modalité "jump shot" nous a dissuadé de l'utiliser sans pour autant faire chuter la performance du modèle, ce qui est une réussite.

⇒ Meneurs | arrières :

Rapport de classification :				
	precision	recall	f1-score	support
0	0.66	0.55	0.60	8282
1	0.54	0.66	0.60	6806
accuracy			0.60	15088
macro avg	0.60	0.60	0.60	15088
weighted avg	0.61	0.60	0.60	15088
Matrice de confusion :				
	pred râté	pred marqué		
obs râté	4519	3763		
obs marqué	2299	4507		

- Nous constatons dans un 1er temps que le recall obtenu sur le jeu de test (66 %) est très proche du recall moyen que ce modèle présentait lors de la validation croisée sur le jeu d'entraînement : les performances du modèle n'ont pas été surestimées par notre procédure d'évaluation.

- Ensuite, le compromis entre recall et précision est plutôt bon (F1-score de 60 %) puisque le recall ET la précision du modèle sont assez proches : il n'y a pas une sur-domination de l'un par rapport à l'autre (par exemple : recall de 80 % et précision de 35 %) qui contribuerait à rendre le F1-score très bon car il s'agit d'une moyenne des 2 scores, alors qu'en réalité le modèle serait proche de l'aléatoire.

- La matrice de confusion sur le jeu de test nous montre que sur les 5 397 tirs marqués, 4 507 sont bien prédits par le modèle et que sur les 6 285 tirs prédits marqués par le modèle, 4 507 sont réellement des tirs marqués.

De même, on notera que les performances de la classe 0 (rappel et précision) ne sont pas mauvaises non plus, sachant que nous cherchions à optimiser celle de la classe 1.

N.B. : nous avons décidé d'ajouter James HARDEN à notre groupe de meneurs. En effet, il est le seul joueur de notre liste de 10 joueurs à pouvoir jouer à la fois aux postes d'arrière et de meneur : son style, son espace de jeu sur le terrain ainsi que ses prises de tir peuvent donc différer de celles de ses 4 camarades, ce qui explique qu'initialement, il n'avait pas été placé dans ce groupe.

Cependant, étant un joueur relativement complet en attaque, il a été très difficile d'améliorer les performances de son modèle individuel, particulièrement au niveau du recall qui ne cessait de stagner autour des 50 %. Nous avons donc choisi de l'intégrer au groupe des meneurs.

⇒ Pivots | Ailiers forts :

Rapport de classification :				
	precision	recall	f1-score	support
0	0.67	0.43	0.52	1661
1	0.60	0.79	0.68	1755
accuracy			0.62	3416
macro avg	0.63	0.61	0.60	3416
weighted avg	0.63	0.62	0.60	3416
Matrice de confusion :				
	pred raté	pred marqué		
obs raté	719	942		
obs marqué	362	1393		

- **Sur 1 755 tirs marqués**, 1 393 tirs (= 79 %) sont repérés par le modèle : autrement dit, 21 % des tirs marqués par Davis et Antetokounmpo sont classés par le modèle comme étant des tirs ratés.


Concrètement, cela signifie que **dans 21 % des cas, pensant que l'adversaire ne marquera suite aux prévisions du modèle, nous passerons la consigne au défenseur de ne pas trop presser le tireur, qui en réalité marquera.**

- **Sur 2 335 tirs prédits marqués** par le modèle, 1 393 (= 60 %) sont réellement des tirs ayant été marqués : autrement dit, 40 % des tirs prédits marqués par le modèle sont en fait des tirs ayant été ratés.


Concrètement, cela signifie que **dans 40 % des cas, pensant que le tireur marquera suite aux prévisions du modèle, nous demanderons au défenseur de mettre une pression maximale sur le tireur voire à un autre défenseur de venir en soutien, alors qu'en réalité, le tireur ne marquerait pas dans cette situation** : ce qui lui laisse une occasion de déborder son vis-à-vis, ou de délivrer une passe décisive à un équipier libre de tout marquage.

5.1.4. Courbes ROC


Les courbes ROC des modèles illustrent le fait que ces modèles font mieux qu'un modèle aléatoire (ce qui est rassurant), mais sont cependant plus proche d'un modèle classifiant les tirs de manière aléatoire (ligne en pointillés) que d'un modèle parfait qui ne se tromperait jamais dans ses prévisions :



Courbe ROC du modèle de random forest pour le groupe des **ailiers/ailiers forts**



Courbe ROC du modèle de régression logistique pour le groupe des **pivots/ailiers**



Courbe ROC du modèle de régression logistique pour le groupe des **meneurs/arrières**

Cependant, il semble difficile d'envisager un déploiement de ces modèles à des fins de prédictions au service d'une franchise NBA par exemple : les modèles ne détectent selon nous pas assez bien les tirs marqués (recall), ce qui fait qu'un trop grand nombre de situations dans lesquelles le tireur serait en position de marquer conduirait à prendre de mauvaises décisions et à se saborder à cause de la prédiction inverse faite par le modèle, ce qui conduirait à encaisser beaucoup de points "faciles".

6. Conclusion finale

Aucune étude sur la prévision de tirs NBA n'utilisant la métrique du F1-score à optimiser mais plutôt l'accuracy, il est difficile de situer la performance de nos modèles par rapport à ceux de ces études.

Nous ne pouvons alors que nous référer à notre objectif initial, qui était d'obtenir un bon compromis entre le recall et la précision afin de juger la performance de nos 3 modèles, en nous posant la question suivante : **utiliserions-nous nos modèles "dans la réalité", à des fins prédictives ?**

- Pour les modèles du groupe des ailiers/ailiers forts et du groupe des ailiers forts/pivots, la réponse à cette question serait NON : les 2 modèles présentent un bon compromis entre les 2 métriques qui sont assez proches et autour des 60 %.

Cependant, les valeurs obtenues pour le recall (63 % pour les ailiers/ailiers forts et 65 % pour les meneurs) ne sont à notre sens pas suffisamment élevées, ce qui fait que trop de tirs réellement marqués sont mal classés par nos modèles, qui produisent alors dans cette situation une erreur aux grosses conséquences, car aboutissant à l'inscription de points "faciles" par l'adversaire.

De plus, le modèle des meneurs utilise parmi ses variables explicatives la variable "action type", dont l'interprétation de la modalité "jump shot" par le créateur du jeu de données porte à confusion.

- En revanche, le modèle sur le groupe des ailiers forts/pivots présente vraiment de très bonnes performances par rapport à ce que l'on souhaitait obtenir : avec 79 % de recall, une petite partie seulement (21 %) des tirs réellement marqués n'est pas détectée par le modèle, ce qui réduit le nombre de cas dans lesquels le tireur pourra inscrire des points "faciles" à cause de la mauvaise prévision du modèle.

En revanche, la précision ne suit malheureusement pas et stagne à 60 % : le très bon rappel du modèle est compensé par une précision moins bonne, qui explique le fait que la courbe ROC du modèle ne soit pas largement au-dessus de celle d'un modèle aléatoire.

- Il est à noter qu'il a été beaucoup plus simple de trouver de la performance chez les ailiers forts/pivots (Giannis Antetokounmpo et Anthony Davis) que chez les autres groupes de joueurs : il fait savoir qu'en NBA, les pivots sont des joueurs ayant généralement vocation à jouer à l'intérieur de la ligne des 3 points, autour du panier. Ainsi, leur espace de jeu ainsi que leurs lieux de tirs sont beaucoup moins denses que ceux des meneurs, des ailiers et des arrières. De plus, nous avons clairement vu lors de l'analyse des 20 jours que Giannis, bien qu'évoluant en poste d'ailier fort, a clairement un jeu proche de celui des pivots et ne privilégie qu'une seule zone de tir : avec les variables dont nous disposons, il a donc été plus facile de trouver des situations clairement identifiables dans lesquelles soit le joueur marque (la plupart du temps), soit il raté.

Ce qui n'est pas le cas des autres joueurs, beaucoup plus complets et polyvalents que des pivots, et dont l'issue des tirs dépend beaucoup moins de ces mêmes variables.

- Dans tous les cas, hormis peut-être le modèle des ailiers forts/pivots, aucun d'eux ne serait probablement développé "dans la vie réelle", sous peine de commettre trop d'erreurs préjudiciables à l'équipe
- Comment aurions-nous pu chercher à obtenir de meilleurs modèles ?

Lors de ce projet, nous avons cherché à exploiter au maximum les variables d'un seul jeu de données, avec quelques variables supplémentaires créées de toute pièce, sans forcément chercher à obtenir d'autres données dans d'autres jeux.

Cependant, il aurait été intéressant d'obtenir des informations cruciales comme : le nom du défenseur au moment du tir, la pression défensive exercée sur le tireur ou encore le niveau défensif global de l'équipe adverse par exemple, qui n'étaient pas présentes dans notre jeu de données.

En connaissant un peu le basketball, le nom du défenseur nous aurait permis de savoir si le vis à vis du tireur est un bon défenseur ou un défenseur médiocre. Il est cependant très difficile de quantifier la pression défensive que met un défenseur sur un attaquant, car aucune statistique ni aucun outil ne permet de mesurer cela. Mais le fait d’au moins savoir si le tir pris est “ouvert” (c’est-à-dire sans personne en face) ou s’il y a un joueur au contre aurait sans doute permis de trouver plus de performance. Enfin, nous aurions par exemple pu essayer de quantifier le niveau défensif de l’équipe adverse en calculant, pour chaque adversaire, le nombre de points moyens (ou médian) encaissés par cette équipe à chaque match lors de cette saison-là.